

**Actividad 4: Reportes breves sobre Modelado de
Datos para Ciencia de Datos**

Vanessa Guadalupe Méndez Lara
Universidad Veracruzana
Facultad de Estadística e Informática
Omar Alexandro Texon Olguin
Xalapa, Veracruz, México

27 de Marzo 2026

El Modelo Relacional

El modelo relacional, fundamentado y propuesto formalmente por el científico Edgar Frank Codd en 1970 durante sus investigaciones en los laboratorios de IBM (García, 2025), se ha consolidado como el modelo principal y estándar en el diseño y gestión de bases de datos. A nivel conceptual, este modelo se basa en la teoría de conjuntos y en la lógica de predicados (García, 2025).

La principal ventaja de este modelo es que permite representar los datos mediante tablas organizadas, facilitando así su manipulación y comprensión, mientras oculta la complejidad de las estructuras físicas de almacenamiento (Elmasri & Navathe, 2015). Esto hace posible que los usuarios trabajen con los datos de manera más intuitiva, enfocándose en la información en sí misma y no en cómo está almacenada internamente.

Además, el modelo relacional ha sido ampliamente adoptado debido a su capacidad para mantener la consistencia de los datos y permitir consultas eficientes, lo cual es especialmente importante en sistemas que manejan grandes volúmenes de información.

El modelo relacional se estructura a partir del concepto de **relación**, que se representa como una tabla (García, 2025). Cada relación está formada por **tuplas** (filas), que representan registros individuales, y por **atributos** (columnas), que describen las características de dichos registros. Además, cada atributo está asociado a un **dominio**, es decir, un conjunto de valores permitidos (Silberschatz, Korth, & Sudarshan, 2019).

Para asegurar la correcta organización de los datos, el modelo utiliza llaves o claves. La llave primaria garantiza que cada registro sea único dentro de la tabla, mientras que la llave foránea permite establecer relaciones entre distintas tablas, manteniendo la integridad referencial (Elmasri & Navathe, 2015).

Otro aspecto importante es el uso de restricciones de integridad, que aseguran que los datos almacenados cumplan ciertas condiciones. Entre estas se encuentran la integridad de entidad, que evita valores nulos en las llaves primarias, y la integridad referencial, que garantiza que las relaciones entre tablas sean válidas.

Desde el enfoque de la ciencia de datos, el modelo relacional es fundamental para asegurar la calidad de la información. Este modelo permite organizar grandes volúmenes de datos bajo una estructura lógica clara, evitando problemas como las anomalías de inserción, eliminación y actualización (Elmasri & Navathe, 2015).

En proyectos de machine learning o analítica la calidad de los datos influye directamente en los resultados obtenidos (Han, Kamber, & Pei, 2011), los datos mal organizados o inconsistentes pueden generar modelos poco confiables o sesgados. Por eso, el modelo relacional contribuye a que los datos sean consistentes, completos y confiables.

Además, al reducir la redundancia y mantener la coherencia de la información (García, 2025), se facilita el proceso de limpieza y preparación de datos, el cual es una de las etapas más importantes dentro de cualquier proyecto de ciencia de datos. De esta forma, los analistas pueden enfocarse en la interpretación y modelado, en lugar de corregir errores estructurales.

Ejemplo breve

Supongamos el desarrollo de un sistema de recomendación para una plataforma de e-commerce. En este caso, la información se organiza en una tabla Clientes (con una llave primaria ID_Cliente) y una tabla Transacciones. Ambas tablas se relacionan mediante el ID_Cliente, que funciona como llave foránea en la tabla de transacciones.

Gracias a esta estructura, es posible analizar los hábitos de compra de cada cliente de manera ordenada y sin duplicidades, lo que permite construir modelos de predicción más precisos. Por ejemplo, se pueden identificar patrones de consumo, frecuencia de compra o productos preferidos.

Además, esta organización evita problemas como la duplicación de registros o inconsistencias en los datos, lo cual mejora significativamente la calidad del análisis y reduce el riesgo de errores en los modelos predictivos, incluyendo problemas como el sobreajuste (overfitting).

ID_Cliente (PK)	Nombre	Edad
1	Ana	25
2	Luis	30

Tabla 1. Ejemplo de la tabla Clientes

ID_Transacción (PK)	ID_Cliente (FK)	Producto
101	1	Laptop
102	2	Celular

Tabla 2. Ejemplo de la tabla Transacciones

El Modelo Entidad-Relación (E-R)

El modelo Entidad-Relación (E-R), propuesto por Peter Chen en 1976 (García, 2025), es una herramienta de modelado conceptual que permite representar de manera clara la estructura de una base de datos. Su objetivo es describir cómo se relacionan los elementos de un sistema dentro de un contexto específico o “minimundo” (Elmasri & Navathe, 2015).

Este modelo funciona como un paso previo al diseño lógico, ya que permite visualizar de forma sencilla las relaciones entre los datos antes de su implementación en una base de datos (Silberschatz, Korth, & Sudarshan, 2019). Gracias a su representación gráfica, facilita la comunicación entre desarrolladores, analistas y usuarios del sistema.

El modelo E-R se compone de tres elementos principales: **entidades**, **atributos** y **relaciones**. Las **entidades** representan objetos o conceptos del mundo real que tienen existencia propia y se muestran como rectángulos. Estas pueden ser entidades fuertes o débiles, dependiendo de si dependen de otra entidad para existir (Elmasri & Navathe, 2015).

Los **atributos** describen las características de las entidades y pueden ser simples, compuestos, multivaluados o derivados (Silberschatz, Korth, & Sudarshan, 2019). Por ejemplo, un atributo compuesto puede dividirse en otros más pequeños, mientras que uno derivado se obtiene a partir de otros datos.

Por otro lado, las **relaciones** representan la forma en que las entidades se conectan entre sí y se ilustran mediante rombos. Estas relaciones no solo indican asociación, sino también cómo interactúan los datos dentro del sistema.

Además, es importante considerar la **cardinalidad**, que indica cómo se relacionan las entidades (1:1, 1:N, M:N), así como las restricciones de participación, que pueden ser totales o parciales (Elmasri & Navathe, 2015). Estos elementos son clave para definir correctamente la estructura de la base de datos.

En ciencia de datos, el modelo E-R es clave en la etapa inicial de comprensión de los datos. Permite identificar claramente las entidades, sus atributos y las relaciones entre ellas, lo cual facilita la organización de la información y su posterior análisis (Han, Kamber, & Pei, 2011), además, entender correctamente estas relaciones es fundamental durante la creación de variables (feature engineering), ya que evita errores al combinar datos o interpretar relaciones que no existen. Esto ayuda a prevenir inconsistencias y mejora la calidad de los modelos.

También permite detectar posibles problemas desde el inicio, como datos redundantes o relaciones mal definidas, lo cual evita errores en etapas posteriores del análisis. En este sentido, el modelo E-R actúa como una base sólida para todo el proceso de análisis de datos.

Ejemplo breve

En un sistema de análisis hospitalario, se pueden identificar las entidades Paciente y Patología, relacionadas mediante Diagnóstico. Esta relación puede ser de muchos a muchos (N:N), ya que un paciente puede tener varias enfermedades y una enfermedad puede presentarse en varios pacientes.

Este modelo permite identificar qué información es relevante para el análisis, como la gravedad de la enfermedad o la frecuencia de consultas. Con base en esto, se pueden construir modelos predictivos orientados a mejorar la atención médica.




Tabla 3. Modelo Entidad - Relación de Diagnóstico en el sistema hospitalario.

Elaboración propia con apoyo de MakeCharts. Disponible en: <https://www.make-charts.com/es/chart/378a6691-f8c0-4752-ab17-874d75aee8d3>

Transformación del modelo E-R al modelo relacional

La transformación del modelo E-R al modelo relacional corresponde a la fase de diseño lógico de una base de datos. Este proceso consiste en convertir el esquema conceptual en un conjunto de tablas que puedan ser implementadas en un sistema gestor de bases de datos (Elmasri & Navathe, 2015).

Es una etapa fundamental, ya que conecta la representación teórica del sistema con su implementación práctica, permitiendo que los datos puedan ser almacenados, consultados y analizados de manera eficiente.

Durante esta transformación, cada entidad fuerte se convierte en una tabla con sus respectivos atributos (Elmasri & Navathe, 2015). Las entidades débiles generan tablas cuya llave primaria depende de la entidad a la que están asociadas (Silberschatz, Korth, & Sudarshan, 2019).

En cuanto a las relaciones, su transformación depende de la cardinalidad. Las relaciones de uno a muchos (1:N) se resuelven agregando una llave foránea en la tabla correspondiente. Por otro lado, las relaciones de muchos a muchos (M:N) requieren la creación de una tabla intermedia que contenga las llaves de ambas entidades (Elmasri & Navathe, 2015; García, 2025).

Además, los atributos multivaluados se separan en tablas independientes para cumplir con la Primera Forma Normal (1NF) (Silberschatz, Korth, & Sudarshan, 2019). Este proceso asegura que los datos sean atómicos y estén correctamente organizados.

Este proceso es fundamental para garantizar que los datos estén correctamente organizados antes de ser utilizados en análisis o modelos predictivos, una transformación adecuada evita problemas como inconsistencias o duplicación de información, lo que facilita la ejecución de consultas precisas (Han, Kamber, & Pei, 2011). También permite realizar combinaciones de tablas (joins) de manera correcta, evitando la generación de datos incorrectos o redundantes. Esto es especialmente importante en ciencia de datos, donde una mala unión de tablas puede afectar directamente los resultados del análisis.

Además, una estructura bien definida permite trabajar con datos más confiables, lo cual mejora la calidad de los modelos y facilita la interpretación de resultados.

Ejemplo breve

En un sistema educativo, las entidades Estudiante y Curso pueden estar relacionadas mediante Inscripción, con una relación de muchos a muchos (M:N). Durante la transformación, se crea una tabla intermedia Inscripción_Estudiante_Curso que contiene las llaves de ambas entidades, junto con atributos como la calificación.

Esto permite analizar el rendimiento académico de los estudiantes de forma precisa y construir modelos que ayuden a predecir su desempeño, evitando errores derivados de datos mal organizados o duplicados.

ID_Estudiante (PK) Nombre

1	Ana
2	Luis
3	María

Tabla 4. Estructura de la entidad Estudiante

ID_Curso (PK) Nombre

101	Matemáticas
102	Física
103	Programación

Tabla 5. Estructura de la entidad Curso

ID_Estudiante (PK, FK) ID_Curso (PK, FK) Calificación

1	101	9.5
1	102	8.7
2	101	7.8
3	103	9.0

Tabla 6. Relación Inscripción entre Estudiante y Curso

Referencias

- Elmasri, R., & Navathe, S. B. (2016). *Fundamentals of database systems* (7th ed.). Pearson.
Recuperado de: <http://debracollege.dspaces.org/bitstream/123456789/168/1/Fundamentals-of-Database-Systems-Pearson-2015-Ramez-Elmasri-Shamkant-B.-Navathe.pdf>
- García, J. C. (2025). *Modelo relacional: Base de datos relacional*. EWebik.
Recuperado de: <https://ewebik.com/base-de-datos/relacionales>
- García, J. C. (2025). *Modelo entidad relación: simbología y características del diagrama entidad relación*. EWebik.
Recuperado de: <https://ewebik.com/base-de-datos/modelo-entidad-relacion>
- Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.
Recuperado de: https://ia800603.us.archive.org/2/items/datamining_201811/DS-book%20u5.pdf
- Silberschatz, A., Korth, H. F., & Sudarshan, S. (2019). *Database system concepts* (7th ed.). McGraw-Hill Education.
Recuperado de: <https://www.mpgcamb.com/wp-content/uploads/2024/12/Abraham-Silberschatz-Henry-F.-Korth-S.-Sudarshan-Database-System-Concepts-McGraw-Hill-Education-2019.pdf>
- García-Molina, H., Ullman, J. D., & Widom, J. (2009). *Database systems: The complete book* (2nd ed.). Pearson.
Recuperado de: <https://web.cs.wpi.edu/~cs585/s17/Books/Books-PDF/DB%20Systems%20The%20Complete%20Book.pdf>